

Decoder-layer breakdown (attention + linear)

qk pv qkv_proj out_proj ffn

